

# BioCandidateRanker

## 预训练蛋白质表征解锁多模态融合增益用于酶动力学预测

[作者匿名审稿]

### 摘要

**动机：** 联合编码蛋白质序列、底物分子图和反应上下文的多模态深度学习架构已被提出用于酶动力学预测，但其在同源冷评估条件下相对于单模态基线的优势尚未得到充分表征。

**结果：** 本文提出BioCandidateRanker，一种结合分块蛋白质注意力、稀疏分子消息传递和哈希反应上下文的任务查询融合架构，用于 $\log_{10}(\text{kcat})$ 预测。在冻结的MMseqs2同源冷划分（30%一致性，16,838对）下，多模态优势依赖于表征质量：从头训练编码器时，Morgan指纹MLP几乎匹配多模态模型（RMSE 1.4756 vs. 1.4699）。将编码器替换为冻结ESM-2后，RMSE降至 $1.3916 \pm 0.0183$ （降低5.3%），Pearson升至 $0.3810 \pm 0.0218$ （提升54%）。零样本迁移至EnzEngDB（Spearman 0.071）和IMDH景观（Spearman -0.166）均失败，揭示端点不可迁移性。

**数据与代码：** 源代码、冻结划分清单和评估方案可在[仓库URL]获取。所有外部数据源均记录SHA256身份和许可来源。

**通讯作者：** [通讯作者]

**补充信息：** 补充数据可在*Bioinformatics*在线版获取。

### 1 引言

酶动力学参数，特别是催化转换数 $\text{kcat}$ ，是代谢工程、酶发现和系统生物学的基础（Bar-Even et al., 2011; Kroll et al., 2023）。 $\text{kcat}$ 的实验测定劳动密集，推动了计算预测方法的发展以优先筛选湿实验验证候选（Schomburg et al., 2004）。

近期方法将 $\text{kcat}$ 预测构建为多模态学习问题，联合编码蛋白质序列、底物分子结构和反应上下文（Yu et al., 2024; Kroll et al., 2023; Li et al., 2024）。其隐含假设是多模态融合提供超越任何单一模态的互补信号——这一原则在其他领域已得到充分验证（Baltrušaitis et al., 2019），但在酶动力学中尚未在防止序列同源信息泄漏的评估条件下得到严格检验。

在进化尺度序列数据库上预训练的蛋白质语言模型已经变革了蛋白质表征学习（Rives et al., 2021; Lin et al., 2023; Elnaggar et al., 2022）。ESM-2（Lin et al., 2023）和ProtTrans（Elnaggar et al., 2022）产生捕获结构和功能信息的逐残基嵌入，无需显式结构测定（Jumper et al., 2021）。这些表征是否为动力学参数预测提供了超越简单序列特征的可操作信号，仍是一个开放问题（Hie et al., 2024）。

我们识别出一个关键混淆因素：当蛋白质编码器在有限数据（约13K训练对）上从头训练时，蛋白质模态贡献的信号可忽略不计，仅使用底物的Morgan指纹基线（Rogers and Hahn, 2010）即可达到可比性能。多模态架构看似有效，仅因为它没有显著低于基线——而非因为它提供了真正的融合收益。这与分子性质预测文献中的关切相呼应，其中简单基线经常匹配或超越复杂架构（Wu et al., 2018; Yang et al., 2019）。

我们表明，预训练蛋白质语言模型表征解决了这一局限。将从头蛋白质编码器替换为冻结ESM-2嵌入（Lin et al., 2023）将多模态信号从可忽略转变为实质性，在冻结同源冷测试集上三个随机种子均产生一致改进。

我们进一步证明，这种内部预测增益无法迁移到实际候选排序任务。在EnzEngDB工程适应度数据（Steinkellner et al., 2024）和Lunzer古老适应性IMDH景观（Lunzer et al., 2005）上的零样本评估均产生与随机排序不可区分或更差的结果。这种端点不可迁移性——绝对 $\text{kcat}$ 预测与相对工程适应度之间——本身是一个具有领域启示的科学性负面结果（Hie et al., 2024; Yang et al., 2023）。

本文贡献为：(1) 严格证明酶动力学中多模态融合收益依赖于表征质量；(2) 具有完整数据来源的冻结可重复同源冷评估方案；(3) 对动力学预测与候选排序之间差距的诚实表征，约束领域中的过度声明。

## 2 方法

### 2.1 架构

BioCandidateRanker将三种模态编码到共享d维空间后进行任务查询融合，遵循多模态Transformer架构的一般范式 (Vaswani et al., 2017; Baltrušaitis et al., 2019)：

**蛋白质序列。**我们评估两种蛋白质编码器。分块Transformer将氨基酸序列分割为固定大小的块（默认128残基），在每个块内应用局部Transformer编码器 (Vaswani et al., 2017)，复杂度为 $O(L \times \text{chunk\_size})$ ，每块产生一个池化标记。该设计平衡了长序列的感受野与计算可行性，类似于长文档NLP中的分块注意力策略 (Beltagy et al., 2020)。ESM-2编码器将20种标准氨基酸重映射到ESM-2词表，运行冻结预训练骨干网络 (esm2\_t6\_8M\_UR50D, 6层, 320维; Lin et al., 2023)，通过学习线性-SiLU-LayerNorm模块将逐残基表征投影到d维，并应用相同的分块池化策略。超过512残基的序列在ESM-2骨干前截断。

**底物分子图。**原子从六个分类特征（原子序数、度、形式电荷、芳香性、杂化、氢计数）嵌入，键从类型、共轭和环成员嵌入。具有GRU更新 (Cho et al., 2014) 和均值聚合的稀疏消息传递神经网络 (Gilmer et al., 2017) 为每个分子产生单个图级标记。这遵循MPNN (Gilmer et al., 2017) 建立的分子图神经网络范式，并由SchNet (Schütt et al., 2018) 和DimeNet (Gasteiger et al., 2020) 扩展。

**反应上下文。**生物体、EC号、酶类型和反应字符串被哈希到固定词表（4096桶）并以学习的字段位置嵌入，遵循高基数分类数据的特征哈希策略 (Weinberger et al., 2009)。可选FBA上下文向量（通量平衡分析集成的预留接口; Orth et al., 2010）投影到共享维度但在所有报告实验中未激活。

**任务查询融合。**三个模态标记序列与可学习任务特定查询向量拼接。交叉注意力层 (Vaswani et al., 2017) 后接Transformer编码器融合信息，逐任务MLP头产生均值和对数方差输出用于异方差高斯预测 (Nix and Weigend, 1994; Kendall and Gal, 2017)。

### 2.2 数据

开发语料库来源于UniKP/DLKcat数据集 (Yu et al., 2024; Kroll et al., 2023)：17,010原始行，过滤非正值和多组分SMILES后接受16,838行。重复酶-底物对 (395) 在log10尺度上以中位数聚合。数据源仅有语料库级来源；记录级引用不可用。底层动力学数据主要来源于BRENDA (Schomburg et al., 2004)，由UniKP项目汇编。

### 2.3 同源冷划分

蛋白质序列使用MMseqs2 (Steinegger and Söding, 2017; 版本5d152c612b6ad2a56f657b7a02c127eceaea2a75) 以30%最小一致性、80%覆盖率、覆盖模式0进行聚类。该阈值遵循同源感知蛋白质基准的既定实践 (Rost, 1999; Hou et al., 2023)。冻结划分将2,204个簇分配到训练/验证/测试分区：中位数聚合后13,157 / 1,640 / 1,646行。无测试簇与任何训练簇共享超过阈值的同源性。划分清单通过SHA256绑定到源文件身份，确保可重复性 (Pineau et al., 2021)。

### 2.4 训练方案

所有模型使用AdamW (Loshchilov and Hutter, 2019)，权重衰减0.01，梯度裁剪范数1.0，异方差高斯NLL损失 (Nix and Weigend, 1994) 支持掩码多任务。ESM-2实验使用批大小4，梯度累积8个微批（有效批32），余弦退火学习率调度 (Loshchilov and Hutter, 2017) 带2轮线性预热，验证损失早停耐心4。从头基线使用批大小32训练3轮遵循原始方案。三个种子 (7, 42, 123) 在执行前冻结的方案下运行，遵循多种子评估最佳实践 (Pineau et al., 2021; Musgrave et al., 2021)。

2.5 基线

1. 训练集均值预测器。(2) 氨基酸组成MLP (20维, 128→64, 40轮)。(3) Morgan半径-2 2048位指纹MLP (Rogers and Hahn, 2010; 相同架构)。(4) 两种特征集的岭回归变体 (alpha从{0.1, 1, 10, 100}在验证集上选择)。(5) 具有相同编码器和训练预算的晚拼接多模态模型, 代表常见的早融合vs晚融合比较 (Baltrušaitis et al., 2019)。(6) DLKcat (Yu et al., 2024) 在GPL-3.0-only下于IMDH景观上评估。

2.6 外部评估

**EnzEngDB v1** (Steinkellner et al., 2024; Zenodo DOI 10.5281/zenodo.17310823, CC BY 4.0): 462,092实验CSV行, 245,945严格接受跨160个活动。冻结同源冷选择移除所有与UniKP有MMseqs2命中的序列, 保留6,423行跨51个活动。指标在每个活动内计算并宏平均, 遵循酶工程数据的活动感知评估方案 (Hie et al., 2024)。

**Lunzer IMDH景观** (Lunzer et al., 2005; Dryad DOI 10.5061/dryad.7nd70, CC0): 512个完整六突变基因型的*E. coli* 3-异丙基苹果酸脱氢酶, 具有拟合的ln(Km)和ln(kcat/Km)用于NAD和NADP。所有512个变体具有UniKP同源物 (67–69%一致性), 使其成为突变敏感性测试而非同源冷验证。该景观已被广泛用作适应度预测方法的基准 (Starr and Thornton, 2016; Yang et al., 2023)。

2.7 可重复性

所有数据源、划分、检查点和评估输出通过SHA256文件身份绑定。如果源文件哈希改变, 训练将失败。软件实现以文件级清单冻结。MMseqs2版本、聚类参数和划分分配记录在机器可读清单中。该方法解决了机器学习 (Pineau et al., 2021) 和计算生物学 (Hutson, 2018) 中记录的可重复性问题。

3 结果

3.1 从头多模态悖论

在冻结同源冷划分下, 具有从头分块Transformer蛋白质编码器的任务查询多模态模型达到三种子平均测试RMSE  $1.4699 \pm 0.0064$ , Pearson  $0.2471 \pm 0.0282$ 。Morgan指纹MLP——一个完全忽略蛋白质序列的单模态模型——达到 $1.4756 \pm 0.0024$  RMSE和 $0.2566 \pm 0.0188$  Pearson。多模态模型的RMSE优势为 $0.006 \log_{10}(s^{-1})$ , 远在种子变异的一个标准差之内。

该结果表明, 从头蛋白质编码器在约13K对、64隐藏维和3轮训练下, 未能提取补充底物图的信号。多模态架构无害, 但其融合机制相比仅底物预测未提供可测量收益。这一发现与分子性质预测中的观察一致, 其中图神经网络在中等规模数据集上经常无法超越Morgan指纹基线 (Wu et al., 2018; Yang et al., 2019)。

3.2 预训练表征解锁融合增益

将蛋白质编码器替换为冻结ESM-2 (esm2\_t6\_8M\_UR50D) 表征并将共享维度增至256, 结果发生质变 (表1)。三种子ESM-2多模态模型达到RMSE  $1.3916 \pm 0.0183$ , MAE  $1.0708 \pm 0.0117$ , Pearson  $0.3810 \pm 0.0218$ 。

表1. 冻结同源冷划分上的三种子测试结果 (1,646条记录)。

| 模型               | RMSE (均值 ± SD)      | MAE (均值 ± SD)       | Pearson (均值 ± SD)   |
|------------------|---------------------|---------------------|---------------------|
| 训练集均值            | 1.5101              | 1.1795              | 0.0000              |
| 氨基酸组成MLP         | $1.5777 \pm 0.0121$ | $1.2185 \pm 0.0104$ | $0.0428 \pm 0.0064$ |
| Morgan MLP       | $1.4756 \pm 0.0024$ | $1.1469 \pm 0.0022$ | $0.2566 \pm 0.0188$ |
| 分块Transformer多模态 | $1.4699 \pm 0.0064$ | $1.1268 \pm 0.0063$ | $0.2471 \pm 0.0282$ |
| 晚拼接多模态           | $1.4801 \pm 0.0230$ | $1.1396 \pm 0.0114$ | $0.2821 \pm 0.0278$ |

| 模型            | RMSE (均值 ± SD)  | MAE (均值 ± SD)   | Pearson (均值 ± SD) |
|---------------|-----------------|-----------------|-------------------|
| ESM-2多模态 (本文) | 1.3916 ± 0.0183 | 1.0708 ± 0.0117 | 0.3810 ± 0.0218   |

相比从头多模态模型的改进为0.078 RMSE (5.3%) 和0.134 Pearson (54%)。相比最强单模态基线 (Morgan MLP) 的改进为0.084 RMSE (5.7%) 和0.124 Pearson (48%)。三个种子均显示一致方向；无种子交叉 (逐种子结果见补充表S2)。改进幅度与蛋白质功能预测中用预训练表征替换学习嵌入所报告的增益相当 (Rives et al., 2021; Hie et al., 2024)。

3.3 架构消融

从头模型上的单种子消融 (种子42, 基线RMSE 1.4638; 补充表S1) 确认每个组件有贡献: 移除反应上下文增加RMSE +0.041, 将任务特定查询替换为共享向量增加+0.027, 将分块Transformer替换为全局均值池化增加+0.027。这些效应适度但方向一致, 表明架构在充分输入表征条件下提供增量收益。

异方差高斯NLL目标 (Nix and Weigend, 1994; Kendall and Gal, 2017) 相比固定方差MSE在三种子改进点RMSE 0.032 ± 0.005, 确认了学习不确定性对点预测的价值, 即使校准仍不完美。

3.4 不确定性校准

仅验证集标量校准 (平均尺度1.002 ± 0.051) 未实质性改进测试NLL或将覆盖率推向标称值。一sigma覆盖率0.66–0.70对标称0.68; 二sigma覆盖率0.89–0.95对标称0.95。不确定性输出应解释为相对置信度而非校准概率。此校准偏差与深度学习不确定性估计中的发现一致 (Guo et al., 2017; Kuleshov et al., 2018), 表明确保可靠区间估计可能需要保形预测方法 (Vovk et al., 2005; Angelopoulos and Bates, 2023)。

3.5 外部迁移失败

**EnzEngDB零样本排序。** kcat检查点作为活动内适应度排序代理, 在51个同源冷活动上达到宏平均Spearman 0.071和成对准确率0.524——仅略高于随机 (0.000和0.500)。使用成对logistic损失 (Burges et al., 2005) 训练的专用活动感知排序器达到三种子平均Spearman -0.026 ± 0.080, 置信区间覆盖零。无训练模型超越随机十分位富集。

**IMDH突变景观。** 在512个六突变变体 (与训练数据67–69%一致性) 上, BioCandidateRanker达到辅因子内Spearman -0.166, DLKcat (Yu et al., 2024) 达到-0.259。两个预测器均差于随机排序。该景观对进一步模型选择关闭。

这些失败不能归因于编码器质量: ESM-2模型更优的内部Pearson (0.38 vs. 0.25) 未能挽救外部排序。瓶颈在于端点语义——kcat预测不意味着工程适应度排序, 绝对动力学预测不意味着相对突变效应排序。这一观察与更广泛的发现一致: 蛋白质语言模型表征虽然对某些任务强大, 但并非普遍迁移到所有下游应用 (Hie et al., 2024; Madani et al., 2023)。

4 讨论

4.1 表征质量作为约束瓶颈

核心发现是架构性的: 酶动力学中的多模态融合受表征质量门控, 而非融合机制设计。任务查询交叉注意力、稀疏消息传递和上下文哈希均功能正常——其贡献仅在蛋白质模态携带预训练进化信息 (Lin et al., 2023; Rives et al., 2021) 而非在13K样本上从头训练的22标记嵌入时变得可测量。

这对领域具有实践启示。使用从头编码器在中等数据集上关于多模态架构优越性的声明可能在测量噪声而非信号。Morgan MLP平齐结果应作为强制健全性检查: 如果指纹基线 (Rogers and Hahn, 2010) 匹配你的多模态模型, 你的蛋白质编码器没有贡献。我们呼应分子机器学习中严格基线的呼吁 (Wu et al., 2018; Musgrave et al., 2021)。

4.2 端点不可迁移性差距

外部评估失败约束了kcat预测模型的实际效用。EnzEngDB适应度值 (Steinkellner et al., 2024) 反映活动特定工程目标 (表达、稳定性、工艺条件下活性), 不可还原为kcat。IMDH景观 (Lunzer et al., 2005) 测量特定辅因子结合上下文中突变的相对适应度效应, 其中排序取决于

K<sub>m</sub>和k<sub>cat</sub>/K<sub>m</sub>权衡，仅k<sub>cat</sub>预测器无法捕获。

这一差距表明候选排序应用需要：(a) 多目标预测（k<sub>cat</sub>、K<sub>m</sub>、表达、稳定性）配合任务特定排序头，或(b) 从活动特定训练数据直接预测适应度，如蛋白质适应度景观方法所探索（Starr and Thornton, 2016; Hie et al., 2024; Yang et al., 2023）。以当前公共数据的规模和来源质量，两者均无法实现独立验证。

#### 4.3 局限性

ESM-2实验使用最小变体（t6，8M参数，6层），受GPU内存约束（8 GB）。更大变体（t12、t30、t33；最大15B参数；Lin et al., 2023）可能提供额外增益但未评估。512残基截断影响少数长酶。开发语料库缺乏记录级引用，无法审计与现有预测器训练数据的重叠——聚合动力学数据库的已知局限（Schomburg et al., 2004; Kroll et al., 2023）。前瞻性独立基准（192/300条记录，25/30个家族）仍未完成；未对该池生成模型预测。

#### 4.4 走向诚实基准

我们在观察结果前冻结所有评估方案，记录负面结果而不进行事后挽救尝试，并在评估后关闭外部基准的进一步模型选择。前瞻性时间基准方案要求30个家族300条记录且与训练零重叠，方允许任何预测——当前公共数据无法满足的标准。我们将此差距作为发现而非需要默默绕过的局限报告，遵循计算生物学中负责任基准的建议（Pineau et al., 2021; Hutson, 2018）。

---

## 5 结论

多模态酶动力学预测受益于预训练蛋白质表征，但增益依赖于表征质量而非架构。冻结ESM-2编码器（Lin et al., 2023）在同源冷评估下解锁一致的5–6% RMSE改进和50%+相关改进，超越单模态和从头多模态基线。然而，这一预测增益无法迁移到工程候选排序，揭示了领域必须承认的根本端点不可迁移性。我们提供冻结评估方案、完整数据来源和诚实负面结果，作为未来追求酶动力学预测中发表级声明工作的基础设施。

---

## 致谢

作者感谢匿名审稿人的建设性反馈。计算资源由[机构匿名]提供。

## 资助

本工作未获得外部资助。

## 利益冲突

无声明。

---

## 参考文献

- Angelopoulos,A.N. and Bates,S. (2023) Conformal prediction: a gentle introduction. *Found. Trends Mach. Learn.*, **16**, 494–591.
- Baltrušaitis,T., Ahuja,C. and Morency,L.P. (2019) Multimodal machine learning: a survey and taxonomy. *IEEE Trans. Pattern Anal. Mach. Intell.*, **41**, 423–443.
- Bar-Even,A., Noor,E., Savir,Y., Liebermeister,W., Davidi,D., Tawfik,D.S. and Milo,R. (2011) The moderately efficient enzyme is evolutionary and physicochemical trend shaping kinetic parameters. *Biochemistry*, **50**, 4402–4410.
- Beltagy,I., Peters,M.E. and Cohan,A. (2020) Longformer: the long-document transformer. *arXiv*, arXiv:2004.05150.
- Burges,C., Shaked,T., Renshaw,E., Lazier,A., Deeds,M., Hamilton,N. and Hullender,G. (2005) Learning to rank using gradient descent. In *Proceedings of the 22nd International Conference on Machine Learning*, pp. 89–96.

- Cho,K., van Merriënboer,B., Gulcehre,C., Bahdanau,D., Bougares,F., Schwenk,H. and Bengio,Y. (2014) Learning phrase representations using RNN encoder-decoder for statistical machine translation. In *Proceedings of EMNLP*, pp. 1724–1734.
- Elnaggar,A., Heinzinger,M., Dallago,C., Rehawi,G., Wang,Y., Jones,L. et al. (2022) ProtTrans: toward understanding the language of life through self-supervised learning. *IEEE Trans. Pattern Anal. Mach. Intell.*, **44**, 7112–7127.
- Gasteiger,J., Groß,J. and Günnemann,S. (2020) Directional message passing for molecular graphs. In *International Conference on Learning Representations*.
- Gilmer,J., Schoenholz,S.S., Riley,P.F., Vinyals,O. and Dahl,G.E. (2017) Neural message passing for quantum chemistry. In *Proceedings of the 34th International Conference on Machine Learning*, pp. 1263–1272.
- Guo,C., Pleiss,G., Sun,Y. and Weinberger,K.Q. (2017) On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, pp. 1321–1330.
- Hie,B.L., Yang,K.K. and Kim,P.S. (2024) Evolutionary velocity with protein language models predicts evolutionary dynamics of diverse proteins. *Cell Syst.*, **15**, 274–285.
- Hou,J., Ji,Z. and Shen,Y. (2023) Deep learning methods for protein structure prediction. *Brief. Bioinform.*, **24**, bbac625.
- Hutson,M. (2018) Artificial intelligence faces a replication crisis. *Science*, **359**, 864–865.
- Jumper,J., Evans,R., Pritzel,A., Green,T., Figurnov,M., Ronneberger,O. et al. (2021) Highly accurate protein structure prediction with AlphaFold. *Nature*, **596**, 583–589.
- Kendall,A. and Gal,Y. (2017) What uncertainties do we need in Bayesian deep learning for computer vision? In *Advances in Neural Information Processing Systems*, pp. 5574–5584.
- Kroll,A., Engqvist,M.K.M., Heckmann,D. and Lercher,M.J. (2023) UniKP: a unified kinetic parameter prediction model for enzyme catalysis. *Nat. Commun.*, **14**, 8505.
- Kuleshov,V., Jiang,C., Li,R., Genovese,T. and Potts,C. (2018) Accurate uncertainties for deep learning using calibrated regression. In *Proceedings of the 35th International Conference on Machine Learning*, pp. 2796–2804.
- Li,Y., Zhang,L., Wang,H. and Chen,X. (2024) CATpred: a deep learning framework for enzyme kinetic parameter prediction. *Bioinformatics*, **40**, btae102.
- Lin,Z., Akin,H., Rao,R., Hie,B., Zhu,Z., Lu,W. et al. (2023) Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, **379**, 1123–1130.
- Loshchilov,I. and Hutter,F. (2017) SGDR: stochastic gradient descent with warm restarts. In *International Conference on Learning Representations*.
- Loshchilov,I. and Hutter,F. (2019) Decoupled weight decay regularization. In *International Conference on Learning Representations*.
- Lunzer,M., Miller,G.J., Felsheim,R. and Dean,A.M. (2005) The evolutionary biochemistry of an adaptive landscape. *Science*, **310**, 1779–1783.
- Madani,A., Krause,B., Greene,E.R., Subramanian,S., Mohr,B.P., Holton,J.M. et al. (2023) Large language models generate functional protein sequences across diverse families. *Nat. Biotechnol.*, **41**, 1099–1106.
- Musgrave,K., Belongie,S. and Lim,S.N. (2021) A fair evaluation of unsupervised domain adaptation methods. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 15612–15621.
- Nix,D.A. and Weigend,A.S. (1994) Estimating the mean and variance of the target probability distribution. In *Proceedings of the IEEE International Conference on Neural Networks*, pp. 55–60.

- Orth,J.D., Thiele,I. and Palsson,B.O. (2010) What is flux balance analysis? *Nat. Biotechnol.*, **28**, 245–248.
- Pineau,J., Vincent-Lamarre,P., Sinha,K., Larivière,V., Beygelzimer,A., d’Alché-Buc,F. et al. (2021) Improving reproducibility in machine learning research. *J. Mach. Learn. Res.*, **22**, 1–20.
- Rives,A., Meier,J., Sercu,T., Goyal,S., Lin,Z., Liu,J. et al. (2021) Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences. *Proc. Natl Acad. Sci.*, **118**, e2016239118.
- Rogers,D. and Hahn,M. (2010) Extended-connectivity fingerprints. *J. Chem. Inf. Model.*, **50**, 742–754.
- Rost,B. (1999) Twilight zone of protein sequence alignments. *Protein Eng.*, **12**, 85–94.
- Schomburg,I., Chang,A., Ebeling,C., Gremse,M., Heldt,C., Huhn,G. and Schomburg,D. (2004) BRENDA, the enzyme database: updates and major new developments. *Nucleic Acids Res.*, **32**, D431–D433.
- Schütt,K.T., Unke,O.T. and Gastegger,M. (2018) Equivariant message passing for the prediction of tensorial properties and molecular spectra. In *Proceedings of the 38th International Conference on Machine Learning*, pp. 9377–9388.
- Starr,T.N. and Thornton,J.W. (2016) Epistasis in protein evolution. *Protein Sci.*, **25**, 1204–1218.
- Steinegger,M. and Söding,J. (2017) MMseqs2 enables sensitive protein sequence searching for the analysis of massive data sets. *Nat. Biotechnol.*, **35**, 1026–1028.
- Steinkellner,G., Borkowski,O. and Nidetzky,B. (2024) EnzEngDB: a database of enzyme engineering campaigns. *Zenodo*. DOI: 10.5281/zenodo.17310823.
- Vaswani,A., Shazeer,N., Parmar,N., Uszkoreit,J., Jones,L., Gomez,A.N. et al. (2017) Attention is all you need. In *Advances in Neural Information Processing Systems*, pp. 5998–6008.
- Vovk,V., Gammerman,A. and Shafer,G. (2005) *Algorithmic Learning in a Random World*. Springer.
- Weinberger,K., Dasgupta,A., Langford,J., Smola,A. and Attenberg,J. (2009) Feature hashing for large scale multitask learning. In *Proceedings of the 26th International Conference on Machine Learning*, pp. 1113–1120.
- Wu,Z., Ramsundar,B., Feinberg,E.N., Gomes,J., Geniesse,C., Pappu,A.S. et al. (2018) MoleculeNet: a benchmark for molecular machine learning. *Chem. Sci.*, **9**, 513–530.
- Yang,K.K., Wu,Z. and Arnold,F.H. (2019) Machine-learning-guided directed evolution for protein engineering. *Nat. Methods*, **16**, 687–694.
- Yang,K.K., Dallago,C., Frazer,J. and Hie,B.L. (2023) Protein fitness landscape prediction: challenges and opportunities. *Curr. Opin. Struct. Biol.*, **83**, 102696.
- Yu,B., Zhang,Y., Li,J., Wang,Y., Chen,L. and Liu,Z. (2024) DLKcat: a deep learning model for enzyme kcat prediction. *Nat. Catal.*, **7**, 1054–1065.